

Web Scraping con BeautifulSoup

Tarea rápida 2: *Web Scraping* sobre la tienda de libros:


⇒ <http://books.toscrape.com>

Datos requeridos

- Número de páginas: 50 (las páginas totales que muestra el sitio).
- Precios de los libros.
- Valoraciones.
- Títulos.
- URLs (de las imágenes de los libros).

Trabajo a realizar:

1. Conoce la página: observa las tablas existentes, títulos, imágenes, valoraciones, precios, botones para añadir al cesto de compras, indicaciones de existencias o no, navegación entre páginas (número de página, total y botones "Siguiente", "Más", etc.),...
2. Observa el código fuente de la página (el código HTML) o, mejor aún, con *Google Chrome* da clic derecho sobre la página y selecciona "Inspeccionar". Ajusta la división entre la ventana del inspector y la página web.
3. Selecciona la herramienta siguiente para inspeccionar un objeto (como las imágenes):



4. Con esto podrás determinar la etiqueta que contiene al objeto (y su clase/id CSS) o alguna forma de navegar el árbol XML para llegar al dato que ocupas.
5. Identifica un patrón que puedas utilizar para los URLs de cada página de las 50 totales en las que se muestran todos los libros del sitio. Esto te permitirá almacenar, iterar o visitar cada una de ellas.
6. Imprime el código fuente HTML con indentaciones para que puedas encontrar las etiquetas y atributos de los objetos que buscas:

```
html = urlopen('http://www.pythonscraping.com/pages/page1.html')
bs = BeautifulSoup(html.read(), 'html.parser')

print('\nPrint the markup beautifully:')
print(bs.prettify(formatter='html'))
```

7. Empleando *BeautifulSoup* en Python obten los títulos de los libros en la página actual.
8. Usando *BeautifulSoup* en Python obtén los precios de los libros en la página actual.
9. Obtén las valoraciones de los libros en la página actual. En este punto considera el uso de la función `tag.attrs.items()` , por ejemplo:

```
t = bs.find_all('p', class_='start-rating')
k, v = t.attrs.items()
print(k, v)
```

10. Obtén los URLs de las imágenes. No olvides que el atributo `src` de las imágenes es relativo (inicia con `../`), por lo que hay que substituir los dos puntos por el URL base de la página (que inicia con `http://`).
11. Verifica que tengas la misma cantidad de títulos, precios, valoraciones y URLs.
12. Repite el proceso para cada página que vas a procesar. **NO substituyas** la información de la página anterior, la debes ir acumulando.
13. Crea un *Dataframe* de **Pandas** con **TODA** la información recolectada (las columnas deben ser: `Título` , `Precio` , `Valoraciones` y `URLs`).

14. Elimina los símbolos de la moneda en la que están los precios (deja sólo números con punto decimal).
 15. Ordena el dataframe *inplace* de acuerdo a la columna `Precio` en orden descendente.
 16. Si las valoraciones las tienes como cadena de texto cámbialas a valores numéricos equivalentes ('1' $\Rightarrow$ 1, '2' $\Rightarrow$ 2, '3' $\Rightarrow$ 3, '4' $\Rightarrow$ 4 y '5' $\Rightarrow$ 5).
 17. Verifica los tipos de datos de cada columna.
 18. Convierte al tipo correcto la(s) columna(s) que no lo tengan.
 19. ¿Existe correlación entre los precios y las valoraciones de los libros?
 20. Muéstralo de forma gráfica (tú eliges la gráfica que mejor lo represente, en tu opinión).
 21. No olvides entregar la libreta de Jupyter Lab con tus datos de identificación.
-

$\Rightarrow$ Límite de entrega: **30 de abril de 2025, 11:59:59 P. M.**